



Vergleich von linear mixed models und mixed effects ANOVA zur Analyse des klassischen Therapie-Evaluationsdesigns

Comparison of linear mixed models and mixed effects ANOVA for the analysis of the classical therapy evaluation design

Wo wir stehen

Week	Lecture title
1	Introduction: reproducibility and simulation
2	Everything is Regression
3	Means and Intercepts
4	Slopes and Change
5	t-tests and one-way ANOVA
6	Mixed ANOVA (and multilevel models)
7	ANCOVA and (good and bad) controls
8	Linear and logistic regression
9	Latent variable modelling
10	Power analysis and the null hypothesis
11	Measurement error
12	Missingness
13	Everything is Still Regression

Lektüre

Kapitel 11 („Everything is Regression“) des Monte-Carlo-Simulationslehrbuchs (Hussey & Cummins, 2026)

simulations.tidyverse.se

In R and tidyverse



Understanding Statistics

through Monte Carlo simulations

Ian Hussey & Jamie Cummins

Lernziele

Die Bestandteile des klassischen Therapie-Evaluationsdesigns beschreiben: d. h. einer randomisierten kontrollierten Studie

Zwischen festen und zufälligen Effekten sowie zwischen zufälligen Intercepts und zufälligen Slopes unterscheiden

Gegenüberstellen, wie gemischte ANOVA und Mehrebenenmodelle mit festen und zufälligen Effekten umgehen

Zeigen, wie das Nichtmodellieren wichtiger zufälliger Effekte die Type-I-Fehlerrate erhöhen kann

Zur Erinnerung


Beispiele verwenden simulierte Daten

Alle Codes, Daten und Abbildungen befinden sich auf der GitHub-Seite des Kurses.

Englische und deutsche Folien ebenfalls auf GitHub.

Wir verwenden Simulationen und simulierte Daten.

Kurs-GitHub




Zur Erinnerung

Statistische Notation

abhängige Variable $\sim$ unabhängige Variable(n)

Zur Erinnerung


Ein Mittelwert ist ein reines Intercept-Modell



Zur Erinnerung


depression ~ 1

Ein Mittelwert ist ein reines Intercept-Modell



Zur Erinnerung


Veränderung ist ein Slope



Zur Erinnerung

depression ~ 1 + timepoint


Veränderung ist ein Slope




Zur Erinnerung

depression ~ 1 + timepoint

Veränderung ist ein Slope




Veränderung ist ein Slope



```
data: real_data$post_treatment_depression_score and real_data$baseline_depression_score
t = -8.2685, df = 506, p-value = 1.204e-15
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -2.033390 -1.252606
sample estimates:
mean difference
 -1.642998
```


Veränderung bewerten



Angenommen,
diese Daten
stammen aus
einer neuen
Therapie.

Können wir aus diesen
Daten schließen, dass
unsere Therapie
Depressionswerte
wirksam reduziert?

Warum bzw.
warum nicht?

Veränderung bewerten: kontrafaktisches Denken


Aus einfachen Prä-Post-Unterschieden können wir keine Veränderung kausal ableiten.

Das liegt daran, dass wir das Kontrafaktische nicht kennen: Was wäre ohne die Intervention geschehen?

Veränderung bewerten: kontrafaktisches Denken

Aus einfachen Prä-Post-Unterschieden können wir keine Veränderung kausal ableiten.

Das liegt daran, dass wir das Kontrafaktische nicht kennen: Was wäre ohne die Intervention geschehen?



Die zuvor gezeigten Daten stammen aus einer realen Studie, in der keine Intervention verabreicht wurde!

Schleider, K.R. et al. A randomized trial of online single-session interventions for adolescent depression during COVID-19. *Journal of the American Academy of Child and Adolescent Psychiatry* 2020; 59(12): 2150-2158.


Veränderung bewerten: kontrafaktisches Denken

Zur Evaluation einer Therapie
benötigen wir:

- Einen kontrafaktischen Vergleich (d. h. eine Kontrollgruppe)
- Randomisierung der Teilnehmenden auf die Behandlungsbedingungen


Randomisierte kontrollierte Studie

Randomisierte kontrollierte Studie



Verändern sich die Werte unseres Outcomes
(z. B. Depressionswerte) von der
Ausgangsmessung bis zur Nachbehandlung
stärker in der Interventionsgruppe als in der
Kontrollgruppe?

Randomisierte kontrollierte Studie



Wenn der Slope die
Veränderung ist,

und wir Veränderungen
vergleichen wollen,


dann können wir die
Slopes vergleichen,
um Veränderung zu
bewerten!

Analyse von RCT-Daten: gemischte ANOVA

Häufigster Ansatz zur Analyse von RCT-Daten:
gemischte ANOVA

Analyse von RCT-Daten: gemischte ANOVA

Häufigster Ansatz zur Analyse von RCT-Daten:
gemischte ANOVA




„Gemischt“, weil es
Between- und Within-
Subject-Faktoren gibt:

Between:
Interventionsbedingung
Within: verschiedene
Messzeitpunkte

Analyse von RCT-Daten: gemischte ANOVA

Häufigster Ansatz zur Analyse von RCT-Daten:
gemischte ANOVA




Standardformel der gemischten ANOVA

$$\text{depression} \sim \text{timepoint} * \text{treatment} + \text{Error}(\text{participant} / \text{timepoint})$$

Analyse von RCT-Daten: gemischte ANOVA

Häufigster Ansatz zur Analyse von RCT-Daten:
gemischte ANOVA



Standardformel der gemischten ANOVA

$\text{depression} \sim \text{timepoint} * \text{treatment} + \text{Error}(\text{participant} / \text{timepoint})$

Anova Table (Type 3 tests)


Response: y

	Effect	df	MSE	F	ges	p.value
1	group	1, 126	37.02	15.60 ***	.085	<.001
2	time	1, 126	12.29	211.63 ***	.295	<.001
3	group:time	1, 126	12.29	53.50 ***	.096	<.001

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '+' 0.1 ' ' 1

Welche Informationen könnte die gemischte ANOVA übersehen?

Klient:innen könnten aus verschiedenen Klinik-Clustern stammen



Klinik 1

Große städtische Klinik, die eine breite Palette psychischer Störungen behandelt und viele Klient:innen betreut.



Klinik 2

Kleine ländliche Klinik, die auf schwere Fälle klinischer Depression spezialisiert ist und wenige Klient:innen betreut.

Welche Informationen könnte die gemischte ANOVA übersehen?

Klient:innen könnten aus verschiedenen Klinik-Clustern stammen

Klient:innen könnten unterschiedliche Therapeut:innen haben



Therapeutin 1: Ana

Niedergelassene Therapeutin mit selbstüberweisenden Klient:innen. Hat im Durchschnitt eine moderate therapeutische Beziehung zu den Klient:innen.



Therapeutin 2: Mila


Arbeitet in einer Akutklinik für schwere Depressionsfälle. Hat im Durchschnitt eine sehr gute therapeutische Beziehung zu den Klient:innen.

Welche Informationen könnte die gemischte ANOVA übersehen?

Klient:innen könnten aus verschiedenen Klinik-Clustern stammen

Klient:innen könnten unterschiedliche Therapeut:innen haben

Viele weitere mögliche Formen von Clustering



Welche Informationen könnte die gemischte ANOVA übersehen?

Klient:innen könnten aus verschiedenen Klinik-Clustern stammen

Klient:innen könnten unterschiedliche Therapeut:innen haben

Viele weitere mögliche Formen von Clustering

Dies verletzt eine spezifische Annahme der ANOVA:

Unabhängigkeit der Beobachtungen

Unser Beispiel: unterschiedliche Therapeut:innen



Therapeutin 1: Ana

Niedergelassene
Therapeutin mit
selbstüberweisenden
Klient:innen. Hat im
Durchschnitt eine moderate
therapeutische Beziehung
zu den Klient:innen.



Therapeutin 2: Mila

Arbeitet in einer Akutklinik
für schwere
Depressionsfälle. Hat im
Durchschnitt eine sehr gute
therapeutische Beziehung
zu den Klient:innen.

Unser Beispiel: unterschiedliche Therapeut:innen



Therapeutin 1: Ana

Niedergelassene
Therapeutin mit
selbstüberweisenden
Klient:innen. Hat im
Durchschnitt eine moderate
therapeutische Beziehung
zu den Klient:innen.




Therapeutin 2: Mila

Arbeitet in einer Akutklinik
für schwere
Depressionsfälle. Hat im
Durchschnitt eine sehr gute
therapeutische Beziehung
zu den Klient:innen.

$\text{depression} \sim \text{timepoint} * \text{treatment} + \text{Error}(\text{participant} / \text{timepoint})$


Unser Beispiel: unterschiedliche Therapeut:innen



**Therapeutin 1:
Ana**




Niedrigere mittlere
Depressionswerte
zu Beginn
Geringere mittlere
Veränderung



Therapeutin 2: Mila



Höhere mittlere
Depressionswerte
zu Beginn
Größere mittlere
Veränderung




Unterschiedliche
Intercepts
Unterschiedliche
Slopes

Umgang mit Variationsquellen

Die Slopes und Intercepts unserer Therapeut:innen unterscheiden sich von den Slopes und Intercepts für Behandlung oder Messzeitpunkt

Ana und Mila sind nur zwei Therapeutinnen aus einer Zufallsstichprobe der Population von Therapeut:innen, die die Intervention künftig durchführen könnten




Umgang mit Variationsquellen

Unsere Behandlungsbedingungen und
Messzeitpunkte sind feste Effekte

Unsere Therapeut:innen hingegen sind zufällige
Effekte

Umgang mit Variationsquellen



Dies nennt man ein
Mehrebenenmodell
(oder lineares gemischtes Modell bzw. Mixed-
Effects-Modell)

Umgang mit Variationsquellen


Wir haben über Intercepts und Slopes für feste Effekte gesprochen. Es gibt auch Intercepts und Slopes für zufällige Effekte.

Zufällige Intercepts bedeuten, dass verschiedene Ausprägungen einer Zufallseffekt-Variablen unterschiedliche Mittelwerte haben.

Zufällige Slopes modellieren nicht nur Unterschiede in Mittelwerten, sondern auch Unterschiede darin, wie stark sie sich über die Zeit verändern.


depression ~ 1 + timepoint * treatment + (1 | therapist)

Zufällige Intercepts




depression ~ 1 + timepoint * treatment + (1 | therapist)

Zufällige Intercepts




depression ~ 1 + timepoint * treatment + (0 + timepoint | therapist)

Zufällige Slopes




depression ~ 1 + timepoint * treatment + (0 + timepoint | therapist)

Zufällige Slopes




depression ~ 1 + timepoint * treatment + (1 + timepoint | therapist)

Zufällige Intercepts und Slopes



depression ~ 1 + timepoint * treatment + (1 + timepoint | therapist)

Zufällige Intercepts und Slopes



Gemischte ANOVA und Mehrebenenmodelle

Für das Design mit zwei Gruppen und zwei Messzeitpunkten

$\text{depression} \sim \text{timepoint} * \text{treatment} + \text{Error}(\text{participant} / \text{timepoint})$

ist äquivalent zu

$\text{depression} \sim 1 + \text{timepoint} * \text{treatment} + (1 | \text{participant})$

wenn:

keine fehlenden Daten vorliegen


keine zusätzliche Quelle
zufälliger Variation vorliegt (z. B.
Therapeut:in)



Welchen Unterschied macht das?

Simulieren wir einige Experimente und finden es heraus!

Simulierte Studie:





Unsere Simulation:

In unserer Simulation führen wir diese Studie 20'000-mal durch, mit folgenden Grundwahrheiten:

Unsere Simulation:

In unserer Simulation führen wir diese Studie 20'000-mal durch, mit folgenden Grundwahrheiten:

Unsere zwei Behandlungen (neue Therapie und Standardbehandlung) haben denselben Effekt auf Depression (Reduktion um 5 Punkte).

Es gibt einen wahren zufälligen Intercept-Effekt für Teilnehmende.

Es gibt einen wahren zufälligen Slope-Effekt für Therapeut:in.

Unsere Simulation:

Wir wissen in unserer Simulation, dass der wahre Interaktionseffekt null ist.

Wie häufig sollten wir $p < .05$ für den Interaktionseffekt erwarten?


Unsere Simulation:

Wir wissen in unserer Simulation, dass der wahre Interaktionseffekt null ist.

Wie häufig sollten wir $p < .05$ für den Interaktionseffekt erwarten?

In 5 % der Fälle (d. h. Alpha)

p-Wert-Verteilung unter der Nullhypothese



Unsere Simulation:

Wir analysieren unsere 20'000 simulierten Studien mit 3 Modellen:

1. Gemischte ANOVA:

$\text{depression} \sim \text{timepoint} * \text{treatment} + \text{Error}(\text{participant} / \text{timepoint})$


2. Mehrebenenmodell mit zufälligem Therapeut:innen-Intercept:

$\text{depression} \sim \text{timepoint} * \text{treatment} + (1 \mid \text{participant}) + (1 \mid \text{therapist})$


3. Mehrebenenmodell mit zufälligem Therapeut:innen-Intercept und -Slope:

$\text{depression} \sim \text{timepoint} * \text{treatment} + (1 \mid \text{participant}) + (1 + \text{timepoint} \mid \text{therapist})$


Unsere Simulation:



Unsere Simulation:



Unsere Simulation:



Wann können wir also ANOVA verwenden?

Wenn das Design balanciert
und tatsächlich einfach ist

Wenn unsere Daten zu dünn sind, um
zufällige Effekte sinnvoll zu schätzen

**Aber ANCOVA ist besser
(nächste Woche)**

Zusammenfassung

Gemischte ANOVA ignoriert Clustering, das bei der Datenerhebung in RCTs häufig auftreten kann

Mehrebenenmodelle sind deutlich flexibler und können daher viel leichter ein akkurateres Modell der Welt abbilden

Modelle, die wichtiges Clustering nicht berücksichtigen – einschließlich gemischter ANOVA –, können zu erhöhten Type-I-Fehlerraten führen

Übungsfragen für die Prüfun



PREPARE

PREPARE

MY COURSES

Intro stats42

Adv methods28

Causal inference19

Meta-research15

THIS WEEK

Lecture 06 — MLMs

Lecture 07 — ANCOVA & baseline

Seminar — RCT analysis

PREPARE — practice session

Adv methods · Lecture 06 · Multilevel models for repeated measuresQ6 / 107 day streak

Multiple choiceAnalyseHard

In a two-arm, two-timepoint therapy RCT, patients are nested within therapists ($ICC \approx 0.10$ due to therapist effects). You simulate 10,000 datasets *under the null* of no treatment effect and analyse each one with a 2×2 mixed ANOVA that ignores therapist clustering. What does the resulting distribution of p-values for the group $\times$ time interaction look like?

FROM THE LECTURE

"Under a true null with no clustering, p-values are uniform on $[0, 1]$ and the test is nominal at α . Once a clustering source like therapist is ignored, the residual variance is mis-partitioned and the sampling distribution of the test statistic no longer matches its reference..."

A

Approximately uniform on $[0, 1]$ — clustering inflates standard errors symmetrically, so the false-positive rate stays at the nominal 5%.

B

Right-skewed with an excess of small p-values — ignoring therapist clustering treats correlated observations as independent, so Type I error is inflated above 5%.

C

Left-skewed with an excess of large p-values — clustering reduces effective sample size, making the test conservative and Type I error fall below 5%.

D

Uniform overall but with a spike near $p = 1$ — the within-subjects error term in mixed ANOVA already absorbs therapist variance, so the test remains calibrated.

Generated fromLecture 06 transcript · 31:40–34:12 · slide 22

Flag question

Skip

Submit answer

Synced 2 min ago

SESSION

Correct

Avg time

Confidence

Est. mastery

CONCEPTS TESTED

null distribution

clustering

ICC

Ty

therapist

mixed ANOVA

54

Wiederholung

Mixed ANOVA vs Linear Mixed Models — interactive simulator

Simulates many 2 × 2 therapy trials with therapists nested in arms (each therapist delivers only one protocol). Fits all three analyses to each trial and plots the resulting p-values for the time × group interaction. Set the true treatment effect to 0 to test calibration (false-positive rate); set it non-zero to test power.

Number of simulations

1005002,000

Therapists per arm

2415

Patients per therapist

41630

True treatment effect (interaction)

-10010

0 = no real effect → rejection rate IS the false-positive rate.


Therapist variability — pre-post change (SD)

025

Run simulation


Each simulated trial: 128 patients (64 per arm, 4 therapists per arm).

Method	Rejection rate (p < .05)	Trials used
Mixed ANOVA	0.324	500
LMM (1 therapist)	0.324	500
LMM (full)	0.054	500



What you're seeing: the true treatment effect is set to 0.00, so each rejection rate above is a measure of false-positive rate. A correctly-calibrated test should sit at .05.

- **Mixed ANOVA:** 0.324
- **LMM (1|therapist):** 0.324
- **LMM (full):** 0.054




Lektüre

Kapitel 12 („Estimation“) des Monte-Carlo-Simulationslehrbuchs (Hussey & Cummins, 2026)

simulations.tidyverse.se

In R and tidyverse



Understanding Statistics

*through Monte Carlo
simulations*

Ian Hussey & Jamie Cummins

Nächste Woche

Auswirkungen von gemischter ANOVA vs. ANCOVA bei der Modellierung von RCT-Daten untersuchen

Wie man entscheidet, welche zufälligen Effekte in Modelle aufgenommen werden sollten

Die Idee guter und schlechter Kontrollvariablen aus Perspektive kausaler Inferenz einführen

Vielen Dank!

Auswirkungen von gemischter ANOVA vs. ANCOVA bei der Modellierung von RCT-Daten untersuchen

Wie man entscheidet, welche zufälligen Effekte in Modelle aufgenommen werden sollten

Die Idee guter und schlechter Kontrollvariablen aus Perspektive kausaler Inferenz einführen